

Handoff — le variabili recuperate da geo_em.d02

Scritto il 2026-09-16, riscritto il 2026-09-17, **riscritto il 2026-09-18** quando il file statico geo_em.d02 è arrivato da LRZ.

Stato: il codice è finito e verificato, e la questione skt è chiusa per misura (§3). La campagna è FERMA e NON va fatta ripartire senza un via esplicito dell'utente.

1. Cosa è successo

geo_em.d02 — dichiarato irrecuperabile in CLAUDE.md, nel registry, in MISSING_VARIABLES.md e nella versione precedente di questo file — è stato ottenuto da LRZ. Sta in /leonardo_work/AIFPT_AILAMIT/CHAPTER/geo (fuori da HOME e fuori dal worktree git), con wrfinput_d02, wrfbdy_d01, namelist.input e namelist.wps.

È il file dei run, verificato e non assunto:

controllo	esito
XLAT_M/XLONG_M contro un wrfout	differenza massima 0.0
LU_INDEX contro IVGTYP (escluso il recode dei laghi)	100.00 % su 2019-08 e 2024-07, 99.95 % su 2024-03 (la differenza è il ghiaccio marino)
SCT_DOM contro ISLTYP	98.5 % (la differenza è acqua/ghiaccio)
HGT_M contro HGT	rms 8.24 m, il ritocco di real.exe

L'unica differenza sistematica è categoria 21 (lago) → 17 (acqua): sf_lake_physics=0. È esattamente il motivo per cui cl è informazione nuova — **19 309 celle che la maschera terra/mare chiama terra contengono un lago sub-griglia**, e il modello quella classe l'ha buttata a runtime.

2. Lo schema: 231 → 246 messaggi

75 → **90 voci**, +15 messaggi, tutti a livello singolo. **Puramente additivo, verificato:** rileggendo un GRIB vecchio e uno nuovo dello stesso timestep, i 231 messaggi preesistenti sono identici byte a byte, 15 aggiunti, 0 modificati.

campo	paramId	da dove
cvl, cvh	27, 28	somma di LANDUSEF sulle classi MODIS basse / alte
tvL, tvh	29, 30	classe dominante bassa / alta tradotta in code table 4.234
slt	43	soglie FAO di ECMWF su CLAYFRAC/SANDFRAC — nessun crosswalk di categorie
cl, dl	26, 228007	LANDUSEF[21] e LAKE_DEPTH (dl su entireLake)
swvl1-4	39-42	medie di strato ERA5 del profilo RUC (SMOIS)
stl1-4	139, 170, 183, 236	idem (TSLB)

Il blocco suolo è integrato, non rietichettato. RUC ha 6 nodi a 0/5/20/40/160/300 cm e un profilo lineare fra loro; gli strati ERA5 (0-7, 7-28, 28-100, 100-289 cm) stanno **tutti dentro** quei nodi, quindi ogni strato è l'integrale esatto del profilo del modello e non si estrapola niente. In pratica una matrice 4×6 costante (convert_to_pressure_levels.SOIL_LAYER_WEIGHTS). Questo è ciò che è cambiato rispetto al 2026-09-17: l'obiezione era contro lo scrivere i valori puntuali, non contro l'integrarli. **tvL è mascherato dove domina lo shrubland** (124 672 celle, 15.8 %

di quelle con $cvl > 0$, Iberia e margine nordafricano): MODIS non porta la fenologia degli arbusti mentre la 4.234 separa sempreverdi (16) da caducifogli (17), e si è scelto di non inventare. cvl dà comunque la copertura. **dl è mascherato fuori dai laghi**: LAKE_DEPTH vale 10.0 m su **99.56** % del dominio, che è il riempimento di default di WPS. Non pubblicati: lai_{lv}/lai_{hv} (il modello porta un solo LAI per cella) e $anor/isor$ (0A/0L non sono l'angolo e l'anisotropia di ECMWF).

3. skt: l'emissività è stata misurata, e ora skt è praticamente esatta

Non serviva scegliere fra ipotesi: l'emissività che WRF ha usato si legge dal file stesso. RRTMG calcola la diagnostica a cielo sereno con la stessa emissività e la stessa TSK, cambiando solo il flusso discendente:

$$LWUPB = eps \cdot \sigma T^4 + (1-eps) \cdot LWDNB$$

$$LWUPBC = eps \cdot \sigma T^4 + (1-eps) \cdot LWDNBC \quad \rightarrow \quad eps = 1 - (LWUPB - LWUPBC) / (LWDNB - LWDNBC)$$

σT^4 sparisce: è un'identità, non un fit, e non richiede nessuna temperatura di riferimento. Esiste ovunque ci siano nubi, cioè il 8-26 % della terra a ogni istante — abbastanza, su 32 file, per coprire ogni categoria presente. **Dispersione interna IQR 0.0000**: ogni cella di una categoria restituisce le stesse quattro cifre. Controllo esatto: sull'acqua, dove la risposta si conosce, restituisce **0.98000** con $p5 = p95$. Dieci categorie su quattordici coincidono con EMISSMIN di VEGPARM.TBL. **Quattro no, e RUC non le prende né da VEGPARM.TBL né da LANDUSE.TBL**:

categoria	misurata	EMISSMIN	errore su skt
3 Deciduous Needleleaf Forest	0.940	0.930	+0.19 K
5 Mixed Forests	0.940	0.930	+0.19 K
7 Open Shrublands	0.880	0.930	-0.96 K
12 Croplands	0.935	0.920	+0.29 K
15 Snow and Ice	0.980	0.950	+0.56 K
16 Barren or Sparsely Vegetated	0.850	0.900	-1.00 K

Le due grosse pesano: il suolo nudo è un quarto del dominio per area, le colture un quinto. **La neve porta l'emissività a 0.98 secca in ogni categoria** — un interruttore, non una miscela. La regola migliore contro i valori esatti è: $0.98 \text{ da } SNOWC \geq 0.01$ in su, miscela lineare sotto (97.96 % dei punti riprodotti a $1e-4$, contro 95.32 % di una miscela pura). Cade quindi anche l'affermazione, che era in questi documenti, che sotto neve l'emissività non fosse ricostruibile. **Risultato**, misurato su file veri dopo la modifica:

	prima	dopo
emissività riprodotta a $1e-4$	14.78 % dei punti	97.96 %
errore su skt	0.277 K RMSE	0.032 K
skt contro la soluzione esatta, sui tre file di prova	—	entro 0.01 K sul 98.4-99.9 % dei punti
gate sul mare aperto $\max skt - SST $	0.0015 K	0.0015 K (invariato)

Tre ipotesi sono state **respinte per misura** — non riproporle:

ipotesi	perché cade
mix pesato su LANDUSEF	porta il gate sul mare da 0.0015 K a 0.98 K. Con $sf_surface_physics=3$ WRF non vede mai LANDUSEF a runtime

ipotesi	perché cade
EMISSMIN + shdfac · (EMISSMAX-EMISSMIN), la formula di inizializzazione di WRF	l'eps misurata è piatta rispetto a VEGFRA dove quella formula imporrebbe +0.04...0.065. Il prato a luglio misura 0.9200 contro lo 0.96 della tabella estiva
EMISSMIN stesso	giusto su dieci categorie, sbagliato sulle quattro sopra

Nota metodologica: S0ILT1 **non** è un riferimento per la pelle — è la temperatura *dentro la neve*. Il confronto col suolo si fa con TSLB[0]. Una misura intermedia che usava S0ILT1 dava 7 K di RMSE ed è stata scartata. Categorie mai misurate perché assenti o rarissime nel dominio (11 Wetland, 14 CropMosaic, 19/20 Tundra, 21 Lake): mantengono EMISSMIN e sono marcate NOT MEASURED nella tabella.

4. Costo misurato

	231 messaggi	246 messaggi
file orario	710.4 MB	749.6 MB (+39.2 MB, +5.5 %)
giorno	17.0 GB	17.9 GB
anno	6.20 TB	6.55 TB
tempo / RAM su 1 core DCGP	~5 min / 19.0 GB	~6 min / 19.9 GB

L'aggiunta è piatta nel tempo (sette campi costanti, otto che variano poco). step_convert_mem: 32G resta giusto. Misure su tre file reali: 749.6 MB (luglio 14Z), 650.3 MB (00Z), 772.4 MB (marzo 12Z).

5. Verifiche fatte

Tutte passate, seguendo i quattro passi di CLAUDE.md:

- --debug-vars sui 15 campi: la cache 3D viene saltata (fix di flat_only, prima ogni campo derivato di superficie leggeva 2.6 GB inutilmente);
- tre conversioni complete come job SLURM: **246 messaggi** ciascuna, luglio 14Z / 00Z / marzo;
- check_grib_sanity.py: checked=3 bad=0;
- suolo ricalcolato indipendentemente in numpy: concordanza relativa **1.5e-8**;
- maschera del suolo == terra della lsm **oraria**, e si muove davvero: 1 304 109 punti a luglio, 1 306 578 a marzo, differenza **2469** — esattamente i punti di ghiaccio marino documentati;
- statiche **identiche byte a byte** fra un file di luglio e uno di marzo, mentre lsm no;
- cvl+cvh+(classi né l'una né l'altra) == 1 a 1.9e-7; dl presente su esattamente 88 785 celle;
- 00Z: accumulazioni ancora esattamente zero;
- additività: 231 messaggi preesistenti invariati.

Un dettaglio trovato strada facendo: CLAYFRAC ha un picco esattamente su 0.35 che in float64 legge 34.999999 e cadeva dal lato sbagliato della soglia FAO dei 35 %, spostando 3922 celle da *fine* a *medium*. Risolto arrotondando a 1e-4 punti percentuali, più fine della spaziatura del dato stesso (~4e-4).

6. Cosa c'è di nuovo nel repo

- **static_ref.py** — legge geo_em.d02 una volta e scrive static_v1/chapter_static_d02.npz (1.8 MB). **Tutte le decisioni di mapping stanno qui**, non nel converter. --check-wrfout testa l'assunzione e si rifiuta di scrivere se le griglie differiscono.
- **hpc/grib_schema_ok.py** — conta i messaggi camminando sulle intestazioni GRIB, senza ec-codes né numpy (i tool grib_* non esistono in questa installazione spack). Serve allo **skip sensibile al contenuto**: i job di convert ora saltano un output solo se ha EXPECTED_MESSAGES messaggi, quindi un cambio di schema si auto-ripara e non serve più un albero nuovo ogni volta.
- Registry, converter, convert_step.sh/convert_day.sh, fetch_step.sh, submit_step_pipeline.py, conf/pipeline.yaml (grib_dir → **grib_v3**, NUOVO static_ref_dir), check_grib_sanity.py (STATIC esteso), e la documentazione (CHAPTER_VARIABLES.md §8 con le tabelle di traduzione, MISSING_VARIABLES.md, CLAUDE.md).

accum_ref_v2 non è stato rinominato e non va rinominato: non si aggiunge nessun accumulatore, i 223 sidecar restano validi, e passare a _v3 costringerebbe a ricaricare wrfout 00Z che non esistono più. La versione del sidecar insegue ACCUMULATED_VARS, quella dell'albero insegue lo schema dei messaggi.

7. Stato operativo e ordine di ripartenza

Fermato il 2026-09-18 alle 17:15, prima di toccare il repo (lezione dei null byte, commit de63194): stop flag rebuild_r24_02_cv.stop, rebuild_r24_03_dl.stop, rebuild_sequence.stop; coda conv_ scesa a 0 e driver tutti morti prima della prima modifica. Gli stop flag di fill2024 sono rimasti dove erano. Cosa c'era a quel punto: **5291 file in grib_v2** a 231 messaggi (2019-06/09, 2024-01/02/03 e 06/09), wrfout_rebuild con ~600 wrfout staged, quota a 55 TB su 100. **Ordine di ripartenza — nessuno di questi passi è stato eseguito:**

1. **wrfout_rebuild, ~600 ore, gratis.** Già a disco. Convertirle per prime in grib_v3 con keep_wrfout=true: validazione end-to-end su scala, zero datamover.
2. **Le ~4392 ore a disco, zero download.** hpc/run_share_conversion.sh: wrfout_share (2019-06-17..09-06 e 2024-06-18..09-12) e wrfout_2024fill (2024-03-18..03-31). keep_wrfout=true, gate 48. ~370 core-ora. **Non si cancella niente.**
3. **Le ~900 ore i cui wrfout sono spariti** (2019-09-07..09, 2024-01, parte di 2024-02): ricarico, ~8 TB dal relay. La lista si ricostruisce da logs/freeze_staged.txt e dal ledger rebuild_r24_02_cv_status.log, **non** dai confini di fase. PHASES_ONLY obbligatorio.
4. **Il resto** (resto di 2019 e 2024, 2025-H1) su hpc/run_year_rebuild.sh.

grib_v2 si cancella **solo** quando grib_v3 ha passato check_grib_sanity sullo stesso insieme di file: è l'unica copia di quelle ~900 ore i cui wrfout non esistono più.

8. Decisioni aperte

1. MISSING_VARIABLES.pdf e CHAPTER_VARIABLES.pdf sono da sottoporre ai colleghi; il §6.1 del primo chiede conferma proprio sulla lista land-surface, che ora è quasi completa.
2. mucape/mucin: i punti indefiniti sono scritti come 0, non come mancanti. Da confermare.
3. Il geo_em è datato 2022-12-31 18Z e l'archivio arriva al 2025: ****ripetere --check-wrfout sul primo wrfout 2025 disponibile**** prima di fidarsi delle statiche per quell'anno.