

Handoff — le variabili recuperate da geo_em.d02

Scritto il 2026-09-16, riscritto il 2026-09-17, **riscritto il 2026-09-18** quando il file statico geo_em.d02 è arrivato da LRZ.

Stato: il codice è finito e verificato. La campagna è FERMA e NON va fatta ripartire senza un via esplicito dell'utente.

1. Cosa è successo

geo_em.d02 — dichiarato irrecuperabile in CLAUDE.md, nel registry, in MISSING_VARIABLES.md e nella versione precedente di questo file — è stato ottenuto da LRZ. Sta in /leonardo_work/AIFPT_AILAMIT/CHAPTER/geo (fuori da HOME e fuori dal worktree git), con wrfinput_d02, wrfbdy_d01, namelist.input e namelist.wps.

È il file dei run, verificato e non assunto:

controllo	esito
XLAT_M/XLONG_M contro un wrfout	differenza massima 0.0
LU_INDEX contro IVGTYP (escluso il recode dei laghi)	100.00 % su 2019-08 e 2024-07, 99.95 % su 2024-03 (la differenza è il ghiaccio marino)
SCT_DOM contro ISLTYP	98.5 % (la differenza è acqua/ghiaccio)
HGT_M contro HGT	rms 8.24 m, il ritocco di real.exe

L'unica differenza sistematica è categoria 21 (lago) → 17 (acqua): sf_lake_physics=0. È esattamente il motivo per cui cl è informazione nuova — **19 309 celle che la maschera terra/mare chiama terra contengono un lago sub-griglia**, e il modello quella classe l'ha buttata a runtime.

2. Lo schema: 231 → 246 messaggi

75 → **90 voci**, +15 messaggi, tutti a livello singolo. **Puramente additivo, verificato:** rileggendo un GRIB vecchio e uno nuovo dello stesso timestep, i 231 messaggi preesistenti sono identici byte a byte, 15 aggiunti, 0 modificati.

campo	paramId	da dove
cvl, cvh	27, 28	somma di LANDUSEF sulle classi MODIS basse / alte
tvL, tvh	29, 30	classe dominante bassa / alta tradotta in code table 4.234
slt	43	soglie FAO di ECMWF su CLAYFRAC/SANDFRAC — nessun crosswalk di categorie
cl, dL	26, 228007	LANDUSEF[21] e LAKE_DEPTH (dL su entireLake)
swvl1-4	39-42	medie di strato ERA5 del profilo RUC (SMOIS)
stl1-4	139, 170, 183, 236	idem (TSLB)

Il blocco suolo è integrato, non rietichettato. RUC ha 6 nodi a 0/5/20/40/160/300 cm e un profilo lineare fra loro; gli strati ERA5 (0-7, 7-28, 28-100, 100-289 cm) stanno **tutti dentro** quei nodi, quindi ogni strato è l'integrale esatto del profilo del modello e non si estrapola niente. In pratica una matrice 4×6 costante (convert_to_pressure_levels.SOIL_LAYER_WEIGHTS). Questo è ciò che è cambiato rispetto al 2026-09-17: l'obiezione era contro lo scrivere i valori puntuali, non contro l'integrarli. **tvL è mascherato dove domina lo shrubland** (124 672 celle, 15.8 %

di quelle con $cvl > 0$, Iberia e margine nordafricano): MODIS non porta la fenologia degli arbusti mentre la 4.234 separa sempreverdi (16) da caducifogli (17), e si è scelto di non inventare. cvl dà comunque la copertura. **dl è mascherato fuori dai laghi**: LAKE_DEPTH vale 10.0 m su **99.56** % del dominio, che è il riempimento di default di WPS. Non pubblicati: lai_{lv}/lai_{hv} (il modello porta un solo LAI per cella) e $anor/isor$ (0A/0L non sono l'angolo e l'anisotropia di ECMWF).

3. skt NON è stato toccato — questione chiusa per misura

L'emissività che WRF ha usato è stata **ricavata dai dati**, non scelta. La relazione $LWUPB - GLW = eps \cdot (\sigma T^4 - GLW)$ è una retta per l'origine la cui pendenza è l'emissività; adattata cella per cella su un ciclo diurno completo (12 istanti, luglio e marzo) risulta una **costante per categoria**: dispersione interna IQR 0.0005–0.0014, e luglio e marzo concordano a 0.0005. Il controllo è esatto: sull'acqua, dove TSK è nota perché è la SST, lo stesso fit restituisce **0.97999** contro 0.980, $R^2 = 1.000000$. Due candidati sono stati **respinti**:

ipotesi	perché cade
mix pesato su LANDUSEF	porta $\max skt-SST $ sul mare aperto da 0.0015 K a 0.98 K . Con $sf_surface_physics=3$ WRF non vede mai LANDUSEF a runtime
EMISSMIN + $shdfac \cdot (EMISSMAX - EMISSMIN)$, la formula con cui WRF stesso inizializza EMISS	l'eps adattata è piatta rispetto a VEGFRA (< 0.001 su tutto l'intervallo) dove quella formula imporrebbe +0.04...0.065. Il caso più pulito è il prato a luglio: 0.9202 adattato, 0.920 EMISSMIN, 0.96 se avesse usato la tabella estiva

Quindi EMISSMIN[IVGTYP] — quello che il converter già fa — è giusto. Contro il livello di suolo a 0 cm su terra senza neve:

superficie	notte	giorno
foreste, savana, prato, urbano (7 classi)	0.03–0.11 K RMSE	0.09–0.22 K
foresta mista, colture	0.12–0.19 K	0.21–0.30 K
arbusteto aperto	0.72 K (bias –0.68)	1.22 K (bias –1.15)
suolo nudo / rado	0.75 K (bias –0.74)	1.54 K (bias –1.52)

Sulle due classi aride skt corre 1–1.5 K più freddo del suolo. Lì il fit vorrebbe un'emissività vicina a **0.85**, che chiuderebbe lo scarto — ma 0.85 sta **sotto ogni emissività di ogni tabella WRF** (il minimo assoluto è 0.88, l'urbano), quindi non può essere ciò che il modello ha usato, e adottarla significherebbe mettere un numero inventato sotto un nome ERA5. **Non "sistemare" questo scarto con un fit**. Nota per chi rilegge le versioni precedenti: una misura intermedia usava S0ILT1 come riferimento e dava 7 K di RMSE con +6 K di bias. Era il campo sbagliato — S0ILT1 è la temperatura *dentro la neve*, non la pelle.

4. Costo misurato

	231 messaggi	246 messaggi
file orario	710.4 MB	749.6 MB (+39.2 MB, +5.5 %)
giorno	17.0 GB	17.9 GB
anno	6.20 TB	6.55 TB
tempo / RAM su 1 core DCGP	~5 min / 19.0 GB	~6 min / 19.9 GB

L'aggiunta è piatta nel tempo (sette campi costanti, otto che variano poco). `step_convert_mem`: 32G resta giusto. Misure su tre file reali: 749.6 MB (luglio 14Z), 650.3 MB (00Z), 772.4 MB (marzo 12Z).

5. Verifiche fatte

Tutte passate, seguendo i quattro passi di `CLAUDE.md`:

- `--debug-vars` sui 15 campi: la cache 3D viene saltata (fix di `flat_only`, prima ogni campo derivato di superficie leggeva 2.6 GB inutilmente);
- tre conversioni complete come job SLURM: **246 messaggi** ciascuna, luglio 14Z / 00Z / marzo;
- `check_grib_sanity.py`: `checked=3 bad=0`;
- suolo ricalcolato indipendentemente in numpy: concordanza relativa **1.5e-8**;
- maschera del suolo == terra della `lsm` **oraria**, e si muove davvero: 1 304 109 punti a luglio, 1 306 578 a marzo, differenza **2469** — esattamente i punti di ghiaccio marino documentati;
- statiche **identiche byte a byte** fra un file di luglio e uno di marzo, mentre `lsm` no;
- `cvl+cvh` (classi né l'una né l'altra) == 1 a $1.9e-7$; dl presente su esattamente 88 785 celle;
- 00Z: accumulazioni ancora esattamente zero;
- additività: 231 messaggi preesistenti invariati.

Un dettaglio trovato strada facendo: `CLAYFRAC` ha un picco esattamente su 0.35 che in float64 legge 34.999999 e cadeva dal lato sbagliato della soglia FAO dei 35 %, spostando 3922 celle da *fine* a *medium*. Risolto arrotondando a $1e-4$ punti percentuali, più fine della spaziatura del dato stesso ($\sim 4e-4$).

6. Cosa c'è di nuovo nel repo

- `static_ref.py` — legge `geo_em.d02` una volta e scrive `static_v1/chapter_static_d02.npz` (1.8 MB). **Tutte le decisioni di mapping stanno qui**, non nel `converter`. `--check-wrfout` testa l'assunzione e si rifiuta di scrivere se le griglie differiscono.
- `hpc/grib_schema_ok.py` — conta i messaggi camminando sulle intestazioni GRIB, senza `ec-codes` né `numpy` (i tool `grib_*` non esistono in questa installazione `spack`). Serve allo **skip sensibile al contenuto**: i job di `convert` ora saltano un output solo se ha `EXPECTED_MESSAGES` messaggi, quindi un cambio di schema si auto-ripara e non serve più un albero nuovo ogni volta.
- Registry, `converter`, `convert_step.sh/convert_day.sh`, `fetch_step.sh`, `submit_step_pipeline.py`, `conf/pipeline.yaml` (`grib_dir` → **`grib_v3`**, NUOVO `static_ref_dir`), `check_grib_sanity.py` (STATIC esteso), e la documentazione (`CHAPTER_VARIABLES.md` §8 con le tabelle di traduzione, `MISSING_VARIABLES.md`, `CLAUDE.md`).

`accum_ref_v2` non è stato rinominato e non va rinominato: non si aggiunge nessun accumulatore, i 223 sidecar restano validi, e passare a `_v3` costringerebbe a ricaricare `wrfout 00Z` che non esistono più. La versione del sidecar insegue `ACCUMULATED_VARS`, quella dell'albero insegue lo schema dei messaggi.

7. Stato operativo e ordine di ripartenza

Fermato il 2026-09-18 alle 17:15, prima di toccare il repo (lezione dei null byte, commit `de63194`): stop flag `rebuild_r24_02_cv.stop`, `rebuild_r24_03_dl.stop`, `rebuild_sequence.stop`; coda `conv_scesa` a 0 e driver tutti morti prima della prima modifica. Gli stop flag di `fill2024` sono rimasti dove erano. Cosa c'era a quel punto: **5291 file in `grib_v2`** a 231 messaggi (2019-06/09,

2024-01/02/03 e 06/09), wrfout_rebuild con ~600 wrfout staged, quota a 55 TB su 100. **Ordine di ripartenza — nessuno di questi passi è stato eseguito:**

1. **wrfout_rebuild, ~600 ore, gratis.** Già a disco. Convertirle per prime in grib_v3 con keep_wrfout=true: validazione end-to-end su scala, zero datamover.
2. **Le ~4392 ore a disco, zero download.** hpc/run_share_conversion.sh: wrfout_share (2019-06-17..09-06 e 2024-06-18..09-12) e wrfout_2024fill (2024-03-18..03-31). keep_wrfout=true, gate 48. ~370 core-ora. **Non si cancella niente.**
3. **Le ~900 ore i cui wrfout sono spariti** (2019-09-07..09, 2024-01, parte di 2024-02): riscarico, ~8 TB dal relay. La lista si ricostruisce da logs/freeze_staged.txt e dal ledger rebuild_r24_02_cv_status.log, **non** dai confini di fase. PHASES_ONLY obbligatorio.
4. **Il resto** (resto di 2019 e 2024, 2025-H1) su hpc/run_year_rebuild.sh.

grib_v2 si cancella **solo** quando grib_v3 ha passato check_grib_sanity sullo stesso insieme di file: è l'unica copia di quelle ~900 ore i cui wrfout non esistono più.

8. Decisioni aperte

1. MISSING_VARIABLES.pdf e CHAPTER_VARIABLES.pdf sono da sottoporre ai colleghi; il §6.1 del primo chiede conferma proprio sulla lista land-surface, che ora è quasi completa.
2. mucape/mucin: i punti indefiniti sono scritti come 0, non come mancanti. Da confermare.
3. Il geo_em è datato 2022-12-31 18Z e l'archivio arriva al 2025: ****ripetere --check-wrfout sul primo wrfout 2025 disponibile**** prima di fidarsi delle statiche per quell'anno.